Arquitectura matemática del código

Aplicación del control óptimo de campo medio a clasificación binaria
Basado en Daudin & Delarue, *arXiv:2507.08486*

Índice

1. Datos: generación y preprocesado **2**
1.1. Generación del conjunto `make_moons` . . . 2
1.2. Normalización (`StandardScaler`) . . . 2

2. Arquitectura del modelo **2**
2.1. Campo vectorial prototípico . . . 2
2.2. Campo efectivo de campo medio . . . 3
2.3. ODE de transporte y flujo . . . 3
2.4. Integración numérica: Runge-Kutta de orden 4 . . . 4
2.5. Clasificador lineal . . . 4

3. Función de pérdida **4**
3.1. Coste total . . . 4
3.2. Entropía cruzada binaria (BCE) . . . 5
3.3. Penalización entrópica . . . 5

4. Entrenamiento **6**
4.1. Optimizador Adam . . . 6
4.2. SGD con tasa de aprendizaje constante . . . 6
4.3. SGLD precondicionado (pSGLD) . . . 6
4.4. Cosine Annealing . . . 7
4.5. Gradient Clipping . . . 8
4.6. Retropropagación . . . 8
4.7. Hiperparámetros de entrenamiento . . . 9

5. Fundamentos teóricos **9**
5.1. Condición Polyak-Łojasiewicz (PL) . . . 9
5.2. Genericidad del minimizador . . . 9

6. Descripción matemática de los experimentos **10**
6.1. Experimento A: Evolución de γ_t . . . 10
6.2. Experimento B: Efecto del parámetro ε . . . 10
6.3. Experimento C: Verificación de la condición PL . . . 10
6.4. Experimento D: Genericidad del minimizador . . . 11
6.5. Experimento E: Robustez de ν^* (make_moons) . . . 11
6.6. Experimento F: Simetría de ν^* en `make_circles` . . . 12
6.7. Experimento G: Problema de convergencia ($N \to \infty$) . . . 12

7. Resumen de la arquitectura **13**

1. Datos: generación y preprocesado

1.1. Generación del conjunto `make_moons`

Se generan N pares (x_i, y_i) con la función `make_moons` de `scikit-learn`. Cada punto pertenece a una de dos clases entrelazadas: $y_i \in \{0, 1\}$, con $N/2$ puntos por clase.

En primer lugar, se generan coordenadas limpias $x_i \in \mathbb{R}^2$: para $\theta \in [0, \pi]$, $x = (\cos\theta, \sin\theta)$ pertenece a la clase 0, y $x = (1 - \cos\theta, 1 - \sin\theta - 0{,}5)$ pertenece a la clase 1. Esto produce dos lunas entrelazadas.

A las coordenadas limpias se les añade ruido gaussiano independiente en cada dimensión:

$$x_i \leftarrow x_i + \eta_i, \qquad \eta_i \sim \mathcal{N}(0, \sigma^2 I_2), \quad \sigma = 0{,}12. \tag{1}$$

1.2. Normalización (`StandardScaler`)

Tras añadir el ruido, se aplica normalización estándar componente a componente. Sea μ_k y s_k la media y desviación típica de la componente k sobre los N puntos. La transformación es:

$$\tilde{x}_i^{(k)} = \frac{x_i^{(k)} - \mu_k}{s_k}, \qquad k = 1, 2. \tag{2}$$

Tras la normalización, cada coordenada tiene media 0 y varianza 1. Esto estabiliza el entrenamiento al colocar los datos en una escala homogénea.

En adelante se denota $x_0^i \in \mathbb{R}^2$ al punto normalizado i-ésimo y $\gamma_0 = \frac{1}{N}\sum_{i=1}^{N} \delta_{(x_0^i, y_0^i)}$ a la medida empírica de los datos de entrenamiento. La base de datos es $\{(x_0^i, y_0^i)\}_{i=1}^{N}$.

2. Arquitectura del modelo

El modelo es una *Mean-Field ResNet* compuesta de dos bloques:

1. Un **campo vectorial de campo medio** (`MeanFieldVelocity`) que define la dinámica de una ODE,
2. un **clasificador lineal** que opera sobre el estado final de la ODE.

2.1. Campo vectorial prototípico

Siguiendo el Ejemplo 1.1 del paper [1], se utiliza el campo vectorial prototípico

$$b(x, a) = \sigma(a_1 \cdot x + a_2)\, a_0, \qquad \sigma = \tanh, \tag{3}$$

donde el *parámetro de control* de cada neurona m es

$$a^m = (a_0^m,\, a_1^m,\, a_2^m,\, b_1^m) \;\in\; \mathbb{R}^2 \times \mathbb{R}^2 \times \mathbb{R} \times \mathbb{R} \;=\; \mathbb{R}^6. \tag{4}$$

Los roles de cada componente son:

- $a_1^m \in \mathbb{R}^2$: *pesos de entrada*; definen la dirección del espacio de features que la neurona m "proyecta". La pre-activación es $a_1^m \cdot x \in \mathbb{R}$.
- $a_2^m \in \mathbb{R}$ (columna temporal de W_1): coeficiente que escala la contribución explícita del tiempo $t \in [0, T]$ a la pre-activación.
- $b_1^m \in \mathbb{R}$: sesgo fijo de la neurona m en $t = 0$.
- $a_0^m \in \mathbb{R}^2$: *pesos de salida*; escalan la contribución de la neurona al campo vectorial en $\mathbb{R}^2$. Su norma $\|a_0^m\|_2$ mide la *importancia* de la neurona.

2.2. Campo efectivo de campo medio

En la aproximación de M partículas (neuronas), la medida de control $\nu_t \approx \frac{1}{M}\sum_{m=1}^{M}\delta_{a^m}$ produce el campo efectivo:

$$F(x,t) = \frac{1}{M}\sum_{m=1}^{M} b(x, a^m(t)) = \frac{1}{M}\sum_{m=1}^{M} \sigma\big(a_1^m \cdot x + a_2^m\, t + b_1^m\big)\, a_0^m. \tag{5}$$

Diferencia con el paper. El paper optimiza sobre trayectorias arbitrarias $(a^m(t))_{t\in[0,T]}$. En la implementación, los parámetros (a_1^m, a_0^m, b_1^m) son **estáticos** (independientes de t), y la dependencia temporal se introduce *explícitamente* añadiendo t como entrada adicional:

$$\text{pre-activación}^m(x,t) = a_1^m \cdot x + a_2^m \cdot t + b_1^m. \tag{6}$$

Esto restringe la familia de controles a aquellos cuya trayectoria $a_2^m \mapsto a_2^m \cdot t + b_1^m$ varía *linealmente* en t, pero preserva la dependencia temporal del campo $F(x,t)$.

Implementación matricial. Con $M = 64$ neuronas y $d_1 = 2$:

$$W_1 \in \mathbb{R}^{M\times(d_1+1)}, \quad [W_1]_{m,:} = (a_1^m,\, a_2^m), \quad b_1 \in \mathbb{R}^M, \tag{7}$$

$$W_0 \in \mathbb{R}^{d_1\times M}, \quad [W_0]_{:,m} = a_0^m \quad \text{(sin bias)}. \tag{8}$$

Para N puntos simultáneos $X \in \mathbb{R}^{N\times d_1}$:

$$h = \tanh\big([\,X,\ t\,\mathbf{1}\,]\,W_1^\top + b_1\big) \ \in\ \mathbb{R}^{N\times M}, \qquad F(X,t) = \frac{1}{M}\, h\, W_0^\top \ \in\ \mathbb{R}^{N\times d_1}. \tag{9}$$

El factor $1/M$ se absorbe en la escala de inicialización de W_0.

Total de parámetros de la ODE.

$$\underbrace{M\cdot(d_1+1)}_{\text{pesos } W_1} + \underbrace{M}_{\text{bias } b_1} + \underbrace{d_1\cdot M}_{\text{pesos } W_0} = 64\cdot 3 + 64 + 2\cdot 64 = 384. \tag{10}$$

2.3. ODE de transporte y flujo

El estado $X_t \in \mathbb{R}^2$ de cada punto de dato evoluciona según la ODE de primer orden:

$$\frac{dX_t}{dt} = F(X_t, t), \qquad X_0 = x_0, \qquad t\in[0,T], \quad T = 1. \tag{11}$$

La solución define el *flujo* $\phi_t : \mathbb{R}^2 \to \mathbb{R}^2$ con $X_t = \phi_t(x_0)$. La distribución de features evoluciona como la *medida push-forward*:

$$\gamma_t = (\phi_t)_{\#}\gamma_0, \tag{12}$$

lo que es equivalente a la ecuación de continuidad (ec. 1.3 del paper):

$$\partial_t \gamma_t + \operatorname{div}_x\big(F(x,t)\,\gamma_t\big) = 0. \tag{13}$$

Esta PDE garantiza conservación de masa: los puntos no se crean ni se destruyen, sino que son *transportados* por el campo F.

2.4. Integración numérica: Runge-Kutta de orden 4

La ODE (11) se integra con $n_{\text{steps}} = 10$ pasos de Runge-Kutta 4 (RK4), con paso $\Delta t = T/n_{\text{steps}} = 0{,}1$. En cada paso k (con $t_k = k \cdot \Delta t$):

$$k_1 = F(X_{t_k},\ t_k), \tag{14}$$

$$k_2 = F\big(X_{t_k} + \tfrac{\Delta t}{2}\, k_1,\ t_k + \tfrac{\Delta t}{2}\big)\,, \tag{15}$$

$$k_3 = F\big(X_{t_k} + \tfrac{\Delta t}{2}\, k_2,\ t_k + \tfrac{\Delta t}{2}\big)\,, \tag{16}$$

$$k_4 = F(X_{t_k} + \Delta t\, k_3,\ t_k + \Delta t)\,, \tag{17}$$

$$X_{t_{k+1}} = X_{t_k} + \frac{\Delta t}{6}(k_1 + 2k_2 + 2k_3 + k_4). \tag{18}$$

El error global de RK4 es $\mathcal{O}(\Delta t^4) = \mathcal{O}(10^{-4})$, cuatro órdenes de magnitud mejor que Euler ($\mathcal{O}(\Delta t) = 0{,}1$), al coste de cuatro evaluaciones de F por paso.

2.5. Clasificador lineal

Tras integrar la ODE hasta $t = T$, se obtiene el estado final $X_T \in \mathbb{R}^{N\times 2}$. El clasificador lineal calcula el logit:

$$\ell_i = W \cdot X_T^i + b, \qquad W \in \mathbb{R}^{1\times 2},\ b \in \mathbb{R}, \tag{19}$$

y la probabilidad predicha es:

$$\hat{p}_i = \mathbb{P}(y_i = 1 \mid X_T^i) = \sigma(\ell_i) = \frac{1}{1 + e^{-\ell_i}}. \tag{20}$$

Parámetros del clasificador.

$$\underbrace{1 \times 2}_{\text{pesos } W} + \underbrace{1}_{\text{bias } b} = 3 \text{ parámetros}, \tag{21}$$

lo que representa menos del 1 % del total de parámetros del modelo (387).

Intuición. La ODE aprende a *transportar* la distribución γ_0 (lunas entrelazadas, no separables linealmente) hasta γ_T (clases separadas). El clasificador lineal simplemente lee el resultado: toda la complejidad no lineal está en el flujo.

3. Función de pérdida

3.1. Coste total

La función de pérdida que se minimiza es:

$$J(\theta) = \underbrace{\mathcal{L}_{\text{BCE}}(\theta)}_{\text{coste terminal}} + \varepsilon \cdot \underbrace{\mathcal{E}(\theta)}_{\text{penalización entrópica}}, \tag{22}$$

donde θ denota el conjunto completo de parámetros (W_1, b_1, W_0, W, b) y $\varepsilon > 0$ es el coeficiente de regularización.

3.2. Entropía cruzada binaria (BCE)

El coste terminal es la entropía cruzada binaria (Binary Cross-Entropy) con logits:

$$\mathcal{L}_{\mathrm{BCE}}(\theta) = -\frac{1}{N}\sum_{i=1}^{N}\Big[y_i \log\sigma(\ell_i) + (1-y_i)\log(1-\sigma(\ell_i))\Big], \tag{23}$$

donde $\ell_i = W \cdot X_T^i + b$ y $\sigma(\ell_i) = (1+e^{-\ell_i})^{-1}$. En términos del paper [1], este es el coste terminal $L(X_T, Y)$ del problema de control óptimo:

$$\min_{\nu_t} \mathbb{E}\big[L(X_T, Y)\big] + \varepsilon \int_0^T \cdot E(\nu_t \mid \nu^\infty)\, dt, \tag{24}$$

donde $E(\nu_t \mid \nu^\infty)$ es la divergencia KL relativa al prior ν^∞.

3.3. Penalización entrópica

Motivación teórica. El paper regula la medida de control ν_t mediante la divergencia KL respecto al prior de Gibbs:

$$\nu^\infty \propto \exp(-\ell(a)), \qquad \ell(a) = c_1\,|a|^4 + c_2\,|a|^2\,, \quad c_1 = 0{,}05,\ c_2 = 0{,}5. \tag{25}$$

El término cuártico $c_1\,|a|^4$ es esencial: satisface la condición de *supercoercividad* ($\nabla^2\ell(a) \geq c(1+|a|^2)I$) que garantiza la desigualdad log-Sobolev para ν^∞ y por tanto la condición Polyak-Łojasiewicz (véase Sección 5.1). Un potencial puramente cuadrático ($c_1 = 0$) no sería suficiente.

La KL completa es:

$$\mathrm{KL}(\nu_t \| \nu^\infty) = \underbrace{\mathbb{E}_{\nu_t}[\ell(a)]}_{\text{término de energía}} - \underbrace{H(\nu_t)}_{\text{entropía diferencial}}. \tag{26}$$

Limitación de la implementación. En la implementación, $\nu_t = \frac{1}{M}\sum_{m=1}^{M}\delta_{\theta^m}$ es una suma de deltas de Dirac sobre los parámetros puntuales. La entropía diferencial de una medida discreta respecto a un prior continuo es $-\infty$, por lo que la KL completa no es computable.

Sólo es accesible el **término de energía**:

$$\mathcal{E}(\theta) = \frac{1}{N_p}\sum_{j=1}^{N_p}\Big[c_1\,\theta_j^4 + c_2\,\theta_j^2\Big], \quad c_1 = 0{,}05,\ c_2 = 0{,}5, \tag{27}$$

donde la suma recorre los $N_p = 384$ parámetros de `MeanFieldVelocity` (se *excluyen* los 3 parámetros del clasificador, que son parte del coste terminal, no del control). Dividir por N_p hace que el valor no dependa del tamaño del modelo.

Observación 3.1. En términos prácticos, $\mathcal{E}(\theta)$ es equivalente a regularización $L^4 + L^2$ (*weight decay* polinomial). Este término proporciona el **prior energético** ν^∞, pero no el término de entropía $-H(\nu_t)$ de la KL completa. Para los experimentos B, E y F, el término de entropía se implementa mediante **SGLD** (ruido de Langevin en el gradiente, véase Sección 4.3).

Estructura de a^m para la penalización. Recordando que cada neurona m tiene parámetro $a^m = (a_0^m, a_1^m, a_2^m, b_1^m) \in \mathbb{R}^6$, la norma que aparece en $\ell(a)$ es:

$$|a^m|^2 = \|a_0^m\|^2 + \|a_1^m\|^2 + (a_2^m)^2 + (b_1^m)^2. \tag{28}$$

El término de energía es la esperanza de ℓ bajo la medida empírica $\nu_t = \frac{1}{M}\sum_{m=1}^{M}\delta_{a^m}$:

$$\mathbb{E}_{\nu_t}[\ell(a)] = \frac{1}{M}\sum_{m=1}^{M}\ell(a^m) = \frac{1}{M}\sum_{m=1}^{M}\big(c_1|a^m|^4 + c_2|a^m|^2\big).$$

Como $|a^m|^2 = \sum_j (a_j^m)^2$ descompone en escalares, esta expresión es equivalente a aplicar $c_1\theta_j^4 + c_2\theta_j^2$ a cada parámetro escalar θ_j y promediar — de ahí la forma de la ecuación (27).

Observación 3.2 (Discrepancia en el término cuártico)**.** El paper usa $|a|^4 = \left(\sum_j \theta_j^2\right)^2$; la implementación calcula $\sum_j \theta_j^4$, que omite los términos cruzados $\theta_i^2\theta_j^2$. Ambos son supercoercivos, por lo que las garantías teóricas se preservan.

4. Entrenamiento

La función `train()` implementa tres modos de optimización, cada uno adecuado a un experimento distinto:

Modo	Parámetro	Experimentos	Objetivo
Adam + cosine annealing	(defecto)	A, D	Convergencia rápida
SGD + lr constante	`use_sgd=True`	C	Verificación PL sin artefactos
pSGLD + cosine annealing	`use_sgld=True`	B, E, F, G	Muestreo de ν_t^*

4.1. Optimizador Adam

Se utiliza el optimizador Adam [4] con tasa de aprendizaje $\alpha_0 = 0{,}01$, $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$, $\varepsilon_{\text{Adam}} = 10^{-8}$. En cada paso de gradiente s, para cada parámetro escalar θ:

$$g_s = \nabla_\theta J(\theta^{s-1}), \tag{29}$$

$$m_s = \beta_1 m_{s-1} + (1-\beta_1)\, g_s \qquad \text{(primer momento, media exponencial)}, \tag{30}$$

$$v_s = \beta_2 v_{s-1} + (1-\beta_2)\, g_s^2 \qquad \text{(segundo momento, varianza exponencial)}, \tag{31}$$

$$\hat{m}_s = \frac{m_s}{1-\beta_1^s} \qquad \text{(corrección de sesgo)}, \tag{32}$$

$$\hat{v}_s = \frac{v_s}{1-\beta_2^s}, \tag{33}$$

$$\theta^s = \theta^{s-1} - \alpha_s \frac{\hat{m}_s}{\sqrt{\hat{v}_s} + \varepsilon_{\text{Adam}}}. \tag{34}$$

La corrección de sesgo es importante en los primeros pasos, cuando $m_s \approx (1-\beta_1)g_1$ y $v_s \approx (1-\beta_2)g_1^2$ son aún pequeños. Sin corrección, el paso efectivo sería demasiado grande.

4.2. SGD con tasa de aprendizaje constante

Para el Experimento C (verificación de la condición PL), se usa SGD puro con tasa de aprendizaje *constante* $\alpha = 0{,}01$ y sin ruido:

$$\theta^s = \theta^{s-1} - \alpha\, \nabla_\theta J(\theta^{s-1}). \tag{35}$$

La motivación es que la condición PL es una propiedad **geométrica** del paisaje de J, independiente del optimizador. Con cosine annealing, $\alpha_s \to 0$ al final aplana $J(\theta^s) - J^*$ artificialmente, lo que contamina la estimación de $\hat{\mu}$. Con lr constante, J^* es el mínimo geométrico real del gradient flow.

4.3. SGLD precondicionado (pSGLD)

Para los Experimentos B, E y F, se usa **pSGLD** (*preconditioned Stochastic Gradient Langevin Dynamics*, Li et al. [3]): una extensión de SGLD que utiliza **Adam** como optimizador base y acopla el ruido de Langevin al precondicionador de Adam.

Motivación: por qué Adam como base, no SGD. En este problema los gradientes de la BCE son del orden de 10^{-5}. SGD con $\eta = 0{,}01$ produce pasos de tamaño $\sim 10^{-7}$, insuficientes para converger. Adam adapta la tasa de aprendizaje por componente mediante su precondicionador, garantizando convergencia donde SGD falla.

Fórmula de actualización pSGLD. En cada paso s, tras el paso de Adam:

$$\theta^s \leftarrow \underbrace{\mathrm{Adam}(\theta^{s-1}, \nabla J)}_{\text{paso determinístico}} + \underbrace{\sqrt{2\,\eta_s\,\varepsilon \cdot M_s}\,\xi^s}_{\text{ruido precondicionado}}, \qquad \xi^s \sim \mathcal{N}(0, I), \tag{36}$$

donde $M_s \in \mathbb{R}^{N_p}$ es el vector de precondicionadores componente a componente:

$$M_s[j] = \text{mín}\left(\frac{1}{\sqrt{\hat{v}_s[j]} + \delta},\ 1\right), \qquad \hat{v}_s[j] = \frac{v_s[j]}{1 - \beta_2^s}, \tag{37}$$

con $v_s[j]$ el segundo momento exponencial de Adam para el parámetro j, $\beta_2 = 0{,}999$ y $\delta = 10^{-8}$.

Corrección de sesgo. El término $\hat{v}_s[j] = v_s[j]/(1 - \beta_2^s)$ es el segundo momento sesgado-corregido: en los primeros pasos, $v_s[j] \approx (1 - \beta_2) g_1^2$ es pequeño aunque el gradiente no lo sea; sin corrección, $M_s[j]$ sería artificialmente grande y el ruido explotaría. La corrección garantiza que $\hat{v}_s[j] \to \mathbb{E}[g^2]$ a medida que s crece.

Cota superior en M_s y justificación. Sin la cota $M_s \leq 1$, los parámetros con dirección plana ($\hat{v}_s[j] \approx 0$) producirían $M_s[j] \approx 1/\delta = 10^8$, y el ruido $\sqrt{2\eta\varepsilon \cdot 10^8}$ explotaría incluso para ε pequeño. La cota $M_s \leq 1$ corresponde a usar un hiperparámetro de estabilización $\lambda \geq 1$ (distinto del δ de Adam) en la fórmula $1/(\sqrt{\hat{v}} + \lambda)$, como sugieren Li et al. en su implementación original. Con esta cota, el ruido satisface $\|\text{ruido}\| \leq \sqrt{2\eta_s\varepsilon}$: nunca supera el nivel isotrópico de SGLD estándar.

Necesidad del acoplamiento ruido–precondicionador. Inyectar ruido isotrópico (σ constante para todos los j) después del paso de Adam desacopla la parte estocástica del precondicionador y destruye la distribución estacionaria: la cadena de Markov ya *no* converge a $\nu^* \propto \exp(-J(\theta)/\varepsilon)$. Con el acoplamiento de (36)–(37), la SDE efectiva es la Langevin precondicionada

$$d\theta = -\nabla J\, dt + \sqrt{2\varepsilon M}\, dW, \tag{38}$$

cuya medida estacionaria es $\nu^* \propto \exp(-J(\theta)/\varepsilon)$ bajo el precondicionador M (resultado estándar de difusiones precondicionadas).

Resultado. El ruido precondicionado implementa el **término de entropía** $-H(\nu_t)$ de la KL, haciendo que los parámetros exploren la distribución de Gibbs en lugar de colapsar al MAP. El término energético $\mathcal{E}$ en (27) sigue actuando como el prior ν^∞. Con $\varepsilon = 0$ el ruido es exactamente cero (Adam estándar).

La tasa de aprendizaje sigue cosine annealing ($\eta_s \to 0$), satisfaciendo las condiciones de Robbins-Monro: $\sum_s \eta_s = \infty$, $\sum_s \eta_s^2 < \infty$.

4.4. Cosine Annealing

La tasa de aprendizaje α_s no es constante: sigue un calendario de *cosine annealing* [5] con $\eta_{\text{mín}} = 0$ y $T_{\text{máx}} = n_{\text{epochs}}$:

$$\alpha_s = \frac{\alpha_0}{2}\left(1 + \cos\left(\frac{\pi s}{T_{\text{máx}}}\right)\right), \qquad s = 0, 1, \ldots, T_{\text{máx}}. \tag{39}$$

La tasa arranca en $\alpha_0 = 0{,}01$, decrece suavemente hasta 0 al final del entrenamiento. En Adam (experimentos A, D) y SGLD (B, E, F), el aplanamiento de las curvas de pérdida en las últimas épocas se debe al scheduler, no a una violación de la condición PL. Por eso el Experimento C usa SGD con lr constante (Sección 4.2).

4.5. Gradient Clipping

Para evitar gradientes explosivos en las primeras épocas (cuando los parámetros son aún aleatorios y el campo F puede ser grande), se aplica *gradient clipping* por norma global:

$$g \leftarrow \begin{cases} g & \text{si } \|g\| \leq G_{\text{máx}}, \\ G_{\text{máx}} \dfrac{g}{\|g\|} & \text{si } \|g\| > G_{\text{máx}}, \end{cases} \qquad G_{\text{máx}} = 5. \tag{40}$$

Aquí $g = \nabla_\theta J(\theta)$ es el vector de gradientes concatenado sobre todos los parámetros, y la norma es la euclídea global. El clipping escala el vector entero (no componente a componente), preservando la dirección del gradiente.

En Adam, el segundo momento $\hat{v}_s$ hace de divisor adaptativo, pero sin clipping la actualización puede ser muy grande en la primera época cuando $\hat{v}_s$ todavía no ha acumulado información.

4.6. Retropropagación

El gradiente $\nabla_\theta J$ se calcula automáticamente con `loss.backward()` de PyTorch. El grafo computacional incluye:

1. Diferenciación a través del clasificador lineal ($\partial J/\partial W$, $\partial J/\partial b$).
2. Diferenciación a través del RK4 (cuatro evaluaciones de F por paso, $n_{\text{steps}} = 10$ pasos): $\partial J/\partial X_T \cdot \partial X_T/\partial \theta$ mediante la regla de la cadena.
3. Diferenciación de la penalización entrópica $\partial \mathcal{E}/\partial \theta_j = 4c_1\theta_j^3 + 2c_2\theta_j$.

PyTorch construye el grafo dinámicamente en el paso *forward*, por lo que no es necesario implementar el adjunto del integrador manualmente.

4.7. Hiperparámetros de entrenamiento

Hiperparámetro	Valor	Experimentos	Descripción
N	400	todos	Puntos de entrenamiento
d_1	2	todos	Dimensión del espacio de features
M	64	todos	Neuronas / partículas
T	1.0	todos	Horizonte temporal de la ODE
n_{steps}	10	todos	Pasos RK4
ε	0.01	todos	Temperatura entrópica / regularización
α_0	0.01	todos	Tasa de aprendizaje inicial
β_1, β_2	0.9, 0.999	A, D	Momentos de Adam
n_{epochs}	800 (A), 700 (B–G)	todos	Épocas de entrenamiento
$G_{\text{máx}}$	5.0	todos	Umbral de gradient clipping
c_1	0.05	todos	Coeficiente cuártico del prior
c_2	0.5	todos	Coeficiente cuadrático del prior
Solo pSGLD (experimentos B, E, F, G):			
$\sqrt{2\eta_s \varepsilon M_s}$	variable	B, E, F, G	Escala del ruido precondicionado (por componente)
λ	1	B, E, F, G	Cota superior de M_s (evita explosión en dirs. planas)

Cuadro 1: Hiperparámetros del modelo y el entrenamiento.

5. Fundamentos teóricos

5.1. Condición Polyak-Łojasiewicz (PL)

El paper [1] demuestra (Meta-Teorema 2) que para $\varepsilon > 0$ y condiciones iniciales en un conjunto abierto y denso $\mathcal{O}$, la función de pérdida satisface la *desigualdad de Polyak-Łojasiewicz* (PL) local:

$$\|\nabla J(\theta)\|^2 \;\geq\; 2\mu \cdot (J(\theta) - J^*), \qquad \mu > 0, \tag{41}$$

donde $J^* = \inf_\theta J(\theta)$ es el valor óptimo. Esta condición implica convergencia *exponencial* del gradient descent con tasa de aprendizaje η:

$$J(\theta^s) - J^* \;\leq\; (1 - 2\eta\mu)^s \cdot (J(\theta^0) - J^*). \tag{42}$$

Observación 5.1. La condición PL es más débil que la convexidad fuerte: no implica que el espacio de parámetros sea convexo ni que el mínimo sea único en sentido geométrico, pero sí garantiza que cualquier punto estacionario es global. La clave es que $\varepsilon > 0$: con $\varepsilon = 0$ no hay garantía.

5.2. Genericidad del minimizador

El Meta-Teorema 1 del paper establece que para un conjunto abierto y denso $\mathcal{O}$ de condiciones iniciales γ_0, el problema de control tiene un único minimizador *estable*. Esto predice robustez empírica: distintas inicializaciones de parámetros y distintos datasets deberían producir el mismo J^* (a igualdad de clase de problema).

6. Descripción matemática de los experimentos

6.1. Experimento A: Evolución de γ_t

Objetivo. Visualizar que la ODE transforma γ_0 (lunas no separables) en γ_T (clases separadas).

Protocolo. Se entrena un modelo con $\varepsilon = 0{,}01$, $M = 64$, $T = 1$, $n_{\text{epochs}} = 800$. Tras el entrenamiento, se integra la ODE guardando X_t en $t \in \{0, T/4, T/2, 3T/4, T\}$. Se visualiza la distribución γ_t en cada instante.

Magnitudes visualizadas.

- Snapshots γ_t para $t \in \{0, 0{,}25, 0{,}5, 0{,}75, 1{,}0\}$.
- Trayectorias $t \mapsto X_t^{(i)}$ para 40 partículas seleccionadas.
- Curvas de convergencia: J, BCE, $\mathcal{E}$ vs. época.
- Frontera de decisión final en $\mathbb{R}^2$.

Resultado esperado. γ_T debe ser linealmente separable con accuracy $\approx 1{,}0$.

6.2. Experimento B: Efecto del parámetro ε

Objetivo. Estudiar el efecto del coeficiente de regularización entrópica sobre la convergencia, las fronteras de decisión y el campo de velocidad.

Protocolo. Se entrena un modelo para cada $\varepsilon \in \{0, 10^{-3}, 10^{-2}, 0{,}1, 0{,}5\}$ con **pSGLD** (`use_sgld=True`, Li et al. [3]), manteniendo la misma semilla de inicialización. El uso de pSGLD es coherente con el rol de ε como temperatura entrópica: el ruido precondicionado $\sqrt{2\eta_s \varepsilon M_s}\,\xi$ hace que los parámetros exploren $\nu^* \propto \exp(-J(\theta)/\varepsilon)$. Con $\varepsilon = 0$ el ruido es exactamente cero (Adam estándar).

Magnitudes analizadas.

- **B1 — Curvas de convergencia:** J total, accuracy y $\mathcal{E}$ vs. época para cada ε. Los ejes de J y $\mathcal{E}$ están recortados ($J \leq 0{,}5$, $\mathcal{E} \leq 0{,}15$) para que $\varepsilon = 0{,}5$ no domine la escala; las curvas de accuracy muestran la señal bruta (trazo fino) y una media móvil de ventana 15 (trazo grueso). Predicción: J^* crece con ε (la regularización penaliza la solución óptima "pura"), pero todas las ε convergen a accuracy $\approx 1{,}0$.
- **B2 — Fronteras de decisión y campo de velocidad:** la fila superior muestra la región de decisión $\{x : \hat{p}(x) \geq 0{,}5\}$ para cada ε; la fila inferior muestra el quiver plot del campo $F(x, t = 0{,}5)$ normalizado en dirección (color = magnitud). Predicción: fronteras más suaves para ε mayor; campo más regular.

Trade-off empírico ε vs. $\hat{\mu}_{\text{PL}}$. Empíricamente se observa que $\hat{\mu}_{\text{PL}}$ no crece monotónicamente con ε. Esto no contradice el paper: la teoría garantiza $\mu > 0$ para todo $\varepsilon > 0$, pero no que μ sea monótono. Con ε grande, J^* es mayor (más penalización) y el exceso de coste $(J - J^*)$ en el denominador de la ratio PL puede crecer más que $\|\nabla J\|^2$, reduciendo $\hat{\mu}$.

6.3. Experimento C: Verificación de la condición PL

Objetivo. Verificar empíricamente la desigualdad (41).

Protocolo. Experimento **autocontenido**: entrena sus propios modelos con **SGD + lr constante** (`use_sgd=True`, $\varepsilon \in \{0, 10^{-3}, 10^{-2}, 0{,}1, 0{,}5\}$, 700 épocas). No reutiliza modelos del Experimento B. La motivación es que la condición PL es una propiedad **geométrica** del paisaje de J, independiente del optimizador: con cosine annealing, $\alpha_s \to 0$ aplana $\delta_s = J(\theta^s) - J^*$ artificialmente y contamina $\hat{\mu}$. Con lr constante, J^* es el mínimo geométrico genuino del gradient flow.

En cada época s, se registran:

$$\text{excess cost}: \quad \delta_s = J(\theta^s) - J^*, \qquad \text{grad norm}: \quad G_s = \|\nabla J(\theta^s)\|^2 . \tag{43}$$

El estimador conservador de μ se define como el percentil 10 del ratio

$$\hat{\mu}_{\mathrm{PL}} = \mathrm{P}_{10}\left\{ \frac{G_s}{2\,\delta_s} : s = 1, \ldots, n_{\text{epochs}} \right\} . \tag{44}$$

Paneles generados.

- **C1 — Log-log:** G_s vs. δ_s. Los puntos deben quedar por encima de la recta $G = 2\hat{\mu}\,\delta$.
- **C2 — Semilog:** δ_s vs. época. Caída exponencial confirma la convergencia predicha por (41).
- **C3 — Barras:** $\hat{\mu}_{\mathrm{PL}}$ para cada ε. Confirma $\hat{\mu} > 0$ para todo $\varepsilon > 0$.
- **C4 — Ratio PL:** $G_s/(2\delta_s)$ vs. época (escala log), que debe mantenerse $\geq \hat{\mu}$ en todo momento.

6.4. Experimento D: Genericidad del minimizador

Objetivo. Verificar empíricamente el Meta-Teorema 1: que el minimizador es robusto a cambios en la inicialización y en el dataset.

Protocolo. Se ejecutan tres sub-experimentos con $n_{\text{seeds}} = 10$, 500 épocas, Adam y $\varepsilon \in \{0, 0{,}01\}$:

- **D1 — γ_0 fija, inicialización variable:** `data_seed`$= 42$, `init_seed`$\in \{0, \ldots, 9\}$.
- **D2 — Inicialización fija, γ_0 variable:** `init_seed`$= 2$, `data_seed`$\in \{0, \ldots, 9\}$.
- **D3 — Ambas aleatorias:** `data_seed`=`init_seed`$= s$.

Resultado esperado. D3 tiene la banda de pérdida más ancha (combina ambas fuentes de variabilidad). Con $\varepsilon = 0{,}01$, la condición PL garantiza $\hat{\mu} > 0$ para todo run, pero la regularización no reduce necesariamente la varianza entre seeds (el paper garantiza convergencia desde cualquier punto, no menor dispersión). Las fronteras de decisión de D2 y D3 son topológicamente similares entre sí, verificando el Meta-Teorema 1. La columna derecha de D2/D3 superpone los contornos $P(y = 1|x) = 0{,}5$ solo para runs con acc $\geq 0{,}95$, sobre una nube de puntos de todos los datasets.

6.5. Experimento E: Robustez de ν^* (make_moons)

Objetivo. Verificar que la distribución óptima de parámetros ν^* es robusta a distintas condiciones de entrenamiento: distintas inicializaciones y distintos datasets deben producir distribuciones ν^* similares.

Protocolo. Dos sub-experimentos con $n_{\text{seeds}} = 10, \varepsilon = 0{,}01, 500$ épocas y **pSGLD** (`use_sgld=True`, para explorar la distribución de Gibbs ν^* en lugar del MAP):

- **E-1:** `data_seed`$= 42$ fijo, `init_seed` $\in \{0, \ldots, 9\}$ variable.
- **E-2:** `init_seed`$= 2$ fijo, `data_seed` $\in \{0, \ldots, 9\}$ variable.

Magnitud visualizada. Para cada run se extraen los pesos de salida $a_0^m \in \mathbb{R}^2$ de las $M = 64$ neuronas y se calcula la *importancia*:

$$I^m = \|a_0^m\|_2 . \tag{45}$$

Las importancias se ordenan de mayor a menor y se representan para cada seed, junto con la media $\pm 1\sigma$ sobre las 10 seeds (figura 1×2):

- **Panel izquierdo (E-1):** importancias con init variable, datos fijos. Banda estrecha $\Rightarrow \nu^*$ es robusta a la inicialización.
- **Panel derecho (E-2):** importancias con datos variables, init fija. Banda estrecha $\Rightarrow \nu^*$ es una propiedad de la geometría del problema, no del dataset concreto.

Si el Meta-Teorema 1 se cumple (minimizador único estable), las curvas de importancia deben ser cualitativamente similares entre seeds: mismo "codo" pronunciado en los primeros ranks y misma caída.

6.6. Experimento F: Simetría de ν^* en `make_circles`

Objetivo. Verificar que en `make_circles` (dataset con simetría rotacional SO(2)) la convergencia del modelo es robusta tanto a variaciones del dataset como de la inicialización.

Protocolo. Dos sub-experimentos con $n_{\text{seeds}} = 10$, $n_{\text{epochs}} = 700$, $\varepsilon = 0{,}01$ y **pSGLD** (`use_sgld=True`):

- **F1:** `init_seed`= 4 fija, `data_seed` variable.
- **F2:** `data_seed`= 42 fijo, `init_seed` variable.

Figura. Se muestra un único panel con las curvas de convergencia $J \pm 1\sigma$ para F1 y F2 superpuestas. La banda más estrecha de F1 vs. F2 (o viceversa) indica cuál fuente de variabilidad domina la robustez del entrenamiento.

Métrica de convergencia. Como pSGLD explora la distribución de Gibbs $\nu^* \propto \exp(-J/\varepsilon)$ y no converge puntualmente a J^*, el nivel de pérdida se reporta como $\bar{J}_{\text{final}}$, la media de las últimas 50 épocas, que estima el nivel estacionario de la cadena de Markov.

6.7. Experimento G: Problema de convergencia ($N \to \infty$)

Objetivo. Verificar empíricamente que el valor óptimo del problema de campo medio finito J_N^* converge al valor óptimo del problema de campo medio con infinitas partículas J_∞^* cuando $N \to \infty$, y estimar la tasa de convergencia.

Marco teórico. El paper [1] establece que

$$J_N^* \xrightarrow{N\to\infty} J_\infty^*. \tag{46}$$

Una tasa natural esperada por analogía con la ley de los grandes números es $\text{gap}(N) := J_\infty^* - J_N^* \sim C \cdot N^{-\alpha}$ con $\alpha \approx 0{,}5$. El experimento busca la tasa empírica.

Protocolo. Se consideran $N \in \{25, 50, 100, 200, 400, 800\}$ partículas y $\varepsilon \in \{0, 0{,}01\}$. Para cada combinación (N, ε) se realizan 20 entrenamientos independientes (`n_seeds`= 20) con 700 épocas y **pSGLD** (`use_sgld=True`). Se usa el optimizador pSGLD (no Adam) para que el nivel de ruido sea coherente con el parámetro ε: con $\varepsilon = 0$ el ruido es exactamente cero.

Estimador de J_∞^*. El valor J_∞^* es inaccesible directamente; se aproxima mediante un *test set oráculo*: se evalúa la pérdida BCE (sin término de regularización) del modelo entrenado sobre un conjunto de test de $N_{\text{test}} = 10\,000$ puntos i.i.d. de make_moons (semilla fija = 999). La hipótesis es que, para N grande, el BCE en test tiende a J_∞^* (la pérdida de Bayes en la distribución de datos). El gap se define como:

$$\text{gap}(N) := J_\infty^* - J_N^* \;\approx\; \text{BCE}_{\text{test}}(N_{\text{large}}) - \text{BCE}_{\text{test}}(N). \tag{47}$$

En la práctica, J_∞^* se aproxima con la media de BCE_test sobre las 20 semillas para $N = 800$.

Figura (G_convergence_problem.png). Layout 1×2:

- **G1 — Convergencia de la pérdida en test:** BCE_test (media $\pm 1\sigma$ sobre 20 seeds) vs. N en escala log-log, para $\varepsilon = 0$ y $\varepsilon = 0{,}01$. Evidencia visual de que $\mathrm{BCE_test}(N) \to J^*_\infty$ al crecer N.

- **G2 — Tasa de convergencia del gap:** $\log \mathrm{gap}(N)$ vs. $\log N$ con ajuste lineal (mínimos cuadrados sobre $N \geq 100$), cuya pendiente es $-\alpha$. Los resultados empíricos son: $\varepsilon = 0$: $\alpha \approx 0{,}78$; $\varepsilon = 0{,}01$: $\alpha \approx 0{,}85$. Ambas tasas son más rápidas que la referencia $N^{-0{,}5}$.

Checkpoint incremental. Para soportar interrupciones (sesiones de Colab), los resultados se guardan en `figuras/G_results.npz` tras completar cada valor de N. Al relanzar, las combinaciones (N, ε) ya calculadas se omiten automáticamente.

7. Resumen de la arquitectura

Bloque	Descripción
Datasets	make_moons (A–E, G) y make_circles (F), $N = 400$, normalizados
ODE	$dX_t/dt = F(X_t, t)$, $t \in [0, 1]$, 10 pasos RK4
Campo F	$(1/M) \sum_m \tanh(a_1^m \cdot x + a_2^m t + b_1^m)\, a_0^m,\ \ M = 64$
Parámetros ODE	$W_1 \in \mathbb{R}^{64\times 3}$, $b_1 \in \mathbb{R}^{64}$, $W_0 \in \mathbb{R}^{2\times 64}$ (384 total)
Clasificador	$\ell = W \cdot X_T + b,\ \ W \in \mathbb{R}^{1\times 2},\ \ b \in \mathbb{R}$ (3 total)
Total parámetros	387
Pérdida	$J = \mathrm{BCE} + \varepsilon \cdot \mathcal{E},\ \ \varepsilon = 0{,}01$
Optimizador (A, D)	Adam [4], $\alpha_0 = 0{,}01$, cosine annealing
Optimizador (C)	SGD, $\alpha = 0{,}01$ constante, sin ruido
Optimizador (B, E, F, G)	pSGLD [3], $\theta \leftarrow \mathrm{Adam}(\theta, \nabla J) + \sqrt{2\eta\varepsilon M}\,\xi,\ \ M = \mathrm{mín}(1/\sqrt{\hat{v}} + \delta, 1)$
Gradient clip	$G_{\mathrm{máx}} = 5$ (todos los modos)

Referencias

[1] S. Daudin and F. Delarue, *Genericity of the Polyak-Łojasiewicz inequality for mean-field Neural ODEs with entropic regularization*, arXiv:2507.08486, 2025.

[2] M. Welling and Y. W. Teh, *Bayesian Learning via Stochastic Gradient Langevin Dynamics*, in *International Conference on Machine Learning (ICML)*, 2011.

[3] C. Li, C. Chen, D. Carlson, and L. Carin, *Preconditioned Stochastic Gradient Langevin Dynamics for Deep Neural Networks*, in *AAAI Conference on Artificial Intelligence*, 2016. https://arxiv.org/abs/1512.07666

[4] D. P. Kingma and J. Ba, *Adam: A Method for Stochastic Optimization*, in *International Conference on Learning Representations (ICLR)*, 2015. https://arxiv.org/abs/1412.6980

[5] I. Loshchilov and F. Hutter, *SGDR: Stochastic Gradient Descent with Warm Restarts*, in *International Conference on Learning Representations (ICLR)*, 2017. https://arxiv.org/abs/1608.03983

[6] R. T. Q. Chen, Y. Rubanova, J. Bettencourt, and D. Duvenaud, *Neural Ordinary Differential Equations*, in *Advances in Neural Information Processing Systems (NeurIPS)*, 2018. https://arxiv.org/abs/1806.07366

[7] B. T. Polyak, *Gradient methods for the minimisation of functionals*, *USSR Computational Mathematics and Mathematical Physics*, 3(4):864–878, 1963.

[8] S. Łojasiewicz, *Une propriété topologique des sous-ensembles analytiques réels*, in *Colloques Internationaux du CNRS*, 117:87–89, 1963.